



عنوان پروژه:

بررسی امکان بهبود بازشناسی خودکار گفتار فارسی با ترکیب خروجی  
مدلهای موجود

**Investigating The Possibility of Improving Persian Automatic  
Speech Recognition by Combining Outputs of Existing Models**

نام دانشجو: زهرا توکلی

استاد راهنما: دکتر زینب مالکی

دانشگاه صنعتی اصفهان

تابستان ۱۴۰۵

## ASR یا Automatic Speech Recognition چیست؟

تبدیل سیگنال گفتار به متن نوشتاری.

### هدف اصلی:

یافتن محتمل ترین دنباله‌ی کلمات، با توجه به سیگنال صوتی ورودی.

### دو جزء اصلی مدل های ASR:

#### ۱. مدل آکوستیک (Acoustic Model):

- وظیفه: استخراج ویژگی‌های صوتی یک فایل صوتی. مثل تشخیص اینکه «چه صداهایی» شنیده می‌شود.

#### ۲. مدل زبانی (Language Model):

- وظیفه: تولید یک دنباله‌ی کلمات در زبان مورد نظر. مثل تشخیص اینکه «چه کلماتی» با توجه به فایل صوتی محتمل‌ترند.

### اجزای کمکی مدل‌ها:

- فرهنگ واژگان (Dictionary): می‌تواند به صورت کاراکتری، زیرواژه‌ای، کلمه‌ای و یا آوایی باشد.


### اهمیت و کاربردهای ASR:

- تعامل صوتی با ماشین، زیرنویس خودکار، رونویسی جلسات، مستندسازی بالینی.
- برای فارسی با بیش از ۱۰۰ میلیون گویشور، دقت ASR مستقیماً بر کاربرپذیری این فناوری‌ها اثر می‌گذارد.

## PROBLEM STATEMENT AND MOTIVATION

# PROBLEM STATEMENT AND MOTIVATION

## How Automatic Speech Recognition Works



## تعریف:

زبانی که در مقایسه با زبان‌های پرممنع (مانند انگلیسی، چینی، اسپانیایی)، منابع دیجیتال، پیکره‌های متنی و صوتی برچسب‌خورده، و ابزارهای پردازش زبان طبیعی برای آن به مراتب محدودتر است و یا شامل تنوع لهجه‌ای مستند نشده یا نظام نوشتاری پیچیده و کم‌پردازش شده است.

## چرا مدل‌ها روی این زبان‌ها ضعیف عمل می‌کنند؟

### ۱. سوگیری توزیع داده:

داده‌های آموزشی مدل‌های چندزبانه به شدت به سمت زبان‌های پرممنع متمایل است.

### ۲. واژگان محدود در توکنایزر:

زبان‌های کم‌منبع در دیکشنری توکن‌های مدل‌های چندزبانه سهم بسیار کوچکی دارند.

### ۳. نبود داده‌ی کافی برای تنظیم دقیق:

حتی با وجود مدل‌های پیش‌آموزش دیده، داده‌ی برچسب‌خورده برای فاین‌تیون کافی نیست.

### ۴. تنوع گویشی و لهجه‌ای:

مدل‌های فعلی عمدتاً روی گونه‌ی معیار آموزش دیده‌اند و برای لهجه‌های دیگر افت شدید دارند.

## وضعیت فارسی:

فارسی با بیش از ۱۰۰ میلیون گویشور، به دلیل کمبود داده‌ی برچسب‌خورده، تنوع لهجه‌ها و پیچیدگی‌های خط (هم‌آوایی‌ها، نیم‌فاصله، اعراب)، همچنان در دسته‌ی زبان‌های کم‌منبع قرار می‌گیرد.

# PROBLEM STATEMENT AND MOTIVATION



### ۱. تنوع لهجه‌ها و گویش‌ها:

- فارسی در ایران با لهجه‌های مختلفی چون تهرانی، اصفهانی، یزدی، مشهدی و ... صحبت می‌شود.
- مدل‌های فعلی عمدتاً روی فارسی معیار (تهران) آموزش دیده‌اند.
- نتیجه: افت شدید دقت برای گویشوران غیرمعیار.

## PROBLEM STATEMENT AND MOTIVATION

### ۲. کمبود داده و سوگیری جمعیت‌شناختی:

- دیتاست‌های موجود (مثل Common Voice فارسی) در توزیع سن، جنسیت و منطقه جغرافیایی نامتوازن هستند.
- نتیجه: عملکرد ضعیف برای گروه‌های کم‌نماینده (کودکان، سالمندان، لهجه‌های منطقه‌ای).

### ۳. شرایط ضبط غیرایده‌آل:

- گفتار محاوره‌ای، موسیقی پس‌زمینه، نویز محیطی.
- ترکیب با تنوع لهجه، افت عملکرد را تشدید می‌کند.





## PROBLEM STATEMENT AND MOTIVATION

۱. هم‌آوایی‌های نوشتاری (مشکل بنیادی):
  - نویسه‌های با تلفظ یکسان: مانند حروف ز، ض، ذ، ظ یا حروف ت و ط
  - تمایز این نویسه‌ها صرفاً از روی شکل نوشتاری ممکن است، نه از سیگنال صوتی.
  - انتخاب نویسه صحیح به یک دانش حافظه‌ای نیاز دارد.

۲. ابهام در مرز کلمات:
  - انتخاب بین فاصله و نیم‌فاصله (ZWNJ) که در برچسب‌های دیتاست‌ها ناهماهنگی دارد.

۳. ناهمسانی و ناکافی بودن پیکره‌های متنی:
  - اختلاط نویسه‌های عربی و فارسی (ي/ای، ك/ک).
  - شکاف بین زبان گفتاری و نوشتاری.

۴. پدیده‌ی رمزگردانی (Code-Switching):
  - ورود اصطلاحات انگلیسی در گفتار فارسی (به‌ویژه در حوزه‌های تخصصی).

## PROBLEM STATEMENT AND MOTIVATION

### مدل اول: Whisper (OpenAI)

- معماری رمزگذار-رمزگشای ترنسفورمر (Encoder-Decoder Transformer)
- ۶۸۰,۰۰۰ ساعت داده‌ی چندزبانه (با نظارت ضعیف)


### مدل دوم: MMS (Meta)

- معماری مبتنی بر wav2vec 2.0 + سر CTC (Connectionist Temporal Classification)
- پوشش بیش از ۱,۱۰۰ زبان با داده‌های چند زبانه گسترده (خود نظارتی)
- پشتیبانی بهتر از زبان‌های کم‌منبع

### مدل سوم: مدل‌های NVIDIA NeMo


- معماری FastConformer + CTC/RNN-T/TDT
- ۱.۷ میلیون ساعت داده‌ی چندزبانه

# WHISPER MODEL ARCHITECTURE





# MMS MODEL ARCHITECTURE



## PROBLEM STATEMENT AND MOTIVATION

### رویکرد ۱: تنظیم دقیق (Fine-Tuning)

**ایده:** به‌روزرسانی پارامترهای مدل پیش‌آموزش‌دیده با داده‌ی برچسب‌خورده‌ی زبان هدف با روش‌هایی مانند **فاین‌تیون کامل** (به‌روزرسانی تمام پارامترهای مدل)، **فاین‌تیون لایه‌ای** (انجماد لایه‌های پایین‌تر رمزگذار که ویژگی‌های آکوستیک مستقل از زبان را کدگذاری می‌کنند)، **فاین‌تیون چندمرحله‌ای** (ابتدا فاین‌تیون روی زبان مرتبط، سپس روی زبان هدف، نیازمند نزدیکی واجی بین زبان واسط و زبان هدف)

### رویکرد ۲: پس‌پردازش (Post-Processing)

**ایده:** تصحیح متن خروجی ASR با استفاده از مدل‌های متنی، بدون تغییر در مدل آکوستیک با روش‌هایی مانند **تصحیح مبتنی مدل‌های Seq2Seq** (مانند mT5)، **تصحیح مبتنی بر LLM** (با قابلیت درک زمینه و تولید متن روان و با چالش‌تمایل به تصحیح بیش‌ازحد و بازنویسی متن).

### رویکرد ۳: یادگیری خودنظارتی

**ایده:** پیش‌آموزش رمزگذارهای گفتار روی داده‌های بدون برچسب مانند مدل‌های XLS-R، MMS، XEUS با مزیت کاهش نیاز به داده‌ی برچسب‌خورده.

# THE PROJECT'S CORE IDEA

ایده‌ی اصلی پروژه، ترکیب چندنمایی خروجی‌های ASR به عنوان یک روش پس پردازش 

بررسی خروجی‌های Whisper و MMS روی مجموعه داده فارسی نشان داد:  
خطاهای این دو مدل در بسیاری از موارد مکمل یکدیگرند؛ به این معنا که آنچه یک مدل نادرست بازشناسی می‌کند، ممکن است در خروجی مدل دیگر به درستی ثبت شده باشد.

**چرا خروجی‌ها مکمل یکدیگرند؟**  
ریشه‌ی مکمل بودن خطاها تفاوت در معماری و داده‌ی آموزشی دو مدل است.

**ایده‌ی پروژه: ترکیب چندنمایی**  
**فرض بنیادین:** خروجی هر مدل ASR را می‌توان به عنوان یک «نما» (View) از سیگنال گفتار در نظر گرفت. هر نما حاوی اطلاعاتی است که ممکن است در نمای دیگر مفقود یا مخدوش باشد.

**راه حل پیشنهادی:**  
یک چارچوب تصحیح پس از تشخیص گفتار (Post-ASR Correction) که خروجی دو مدل Whisper و MMS را به عنوان دو نمای موازی دریافت کرده و متن تصحیح شده را تولید می‌کند.  
اگر مدل بتواند به صورت پویا یاد بگیرد که در هر موقعیت به کدام نما اتکا کند، خروجی نهایی از هر یک از مدل‌های منفرد دقیق‌تر خواهد بود.

**پرسش پژوهش**  
آیا با استفاده از یک مدل کوچک می‌توان با ترکیب خروجی چند مدل ASR ناهمگون، خطاهای بازشناسی گفتار فارسی را به طور مؤثر کاهش داد؟

# PROJECT REFERENCE ARTICLE

مقاله مرجع: تصحیح پس از ASR برای زبان راجستانی 

**مسئله:**

زبان راجستانی (خط دواناگری) یک زبان کم منبع است که مدل ASR اختصاصی ندارد. خروجی Whisper و MMS در این زبان خطاهای سیستماتیک و مکمل دارند.

**راه حل:**

ترکیب چندنمایی خروجی دو مدل با مکانیزم ادغام گیت دار در سطح کاراکتر برای بهبود خروجی ASR ها در این زبان.  
**معماری:**

- هم ترازای کاراکتری خروجی دو مدل ASR با الگوریتم فاصله‌ی لونشتاین
- رمزگذار مشترک BiLSTM

• مکانیزم Gated Fusion برای وزن دهی پویا به هر نما

• رمزگشای LSTM با مکانیزم توجه Bahdanau

**مجموعه داده:** IndicTTS Rajasthani (۹,۰۶۰ نمونه)

**دستآورد:** کاهش CER از ~۱۶٪ به ۷.۸۶٪ (کاهش نسبی ۵۲.۶۵٪) و عملکرد بهتر از هر دو مدل تک‌نمایی.

• پرسش پروژه: آیا این موفقیت به فارسی تعمیم می‌یابد؟

# PROJECT REFERENCE ARTICLE

## Post-ASR Correction for Low-Resource Rajasthani Language

**ABHISHEK BHANDARI**, Computer Science and Engineering, Indian Institute of Technology Jodhpur, Jodhpur, India

**GAURAV HARIT**, Computer Science and Engineering, Indian Institute of Technology Jodhpur, Jodhpur, India

**Whisper:** धौलपूरें माय जिला निर्वाचन अधिकारी सगड़ा समाज रा लोगा सुं मतदान करबा खातर अपील करी है।


**MMS:** धौलपूरें माँ जिला निर्वाचन अधिकारी सगड़ा समाजरा लोगा सुँ मतदान करबा खातर अपील करी है।

**Ours:** धौलपुर रै मांय जिला निर्वाचन अधिकारी सगळा समाज रा लोगा सूं मतदान करबा खातर अपील, करी है

**Reference:** धौलपुर रै मांय जिला निर्वाचन अधिकारी सगळा समाज रा लोगा सूं मतदान करबा खातर अपील, करी है



# PROJECT REFERENCE ARTICLE





# WORKS PERFORMED IN THIS PROJECT

## ۱. ساخت و آماده سازی دیتاست:

- استخراج خروجی‌های مدل‌های Whisper و MMS برای دیتاست Common voice v22
- ساخت دیتاست شامل متن مرجع و خروجی مدل‌های ASR
- نرمال سازی برچسب‌ها و خروجی مدل‌های ASR
- حذف داده‌های با برچسب یا خروجی نامعتبر ASR ها
- اصلاح خط الرسم نادرست برخی واژگان دیتاست

## ۳. ارزیابی و تحلیل خروجی مدل نهایی:

- مقایسه‌ی عملکرد مدل‌های مختلف با خطوط پایه
- بررسی توزیع خطاها در خروجی ASR و مدل نهایی
- تحلیل همبستگی مقادیر گیت با موقعیت و درستی نما
- بررسی ماهیت خطاها (هم‌آوایی، درج، حذف، جانشینی)

## ۲. پیاده‌سازی و آموزش مدل:

- پیاده سازی مدل در دو سطح با دیکشنری کاراکتری و زیرواژه ای
- بررسی دو روش همترازی کاراکترهای خروجی مدل‌های ASR (کاراکتر تهی و رشته طولانی تر)
- تنظیم هایپرپارامترها و جلوگیری از بیش‌برازش
- بررسی اثر تغییر تابع هزینه و فرمول ادغام گیت‌ها و سایر روش‌ها برای افزایش پویایی گیت‌ها

## ۴. مقایسه نتایج با نتایج مقاله مرجع:

- تحلیل هم‌آوایی در زبان فارسی
- مقایسه‌ی نتایج با مقاله راجستانی
- تحلیل بنیادی تفاوت ماهیت خطاها در فارسی و راجستانی
- نتیجه‌گیری درباره‌ی عدم تعمیم‌پذیری معماری به زبان فارسی



# DATASET CREATION AND PREPARATION

## معرفی دیتاست و تفکیک داده‌ها

### مجموعه داده اولیه

- زیرمجموعه‌ای پاکسازی شده از دیتاست Common Voice v22 برای زبان فارسی (در Hugging Face با نام `aliydz95/common_voice_22_0_fa`).
- شامل نمونه‌های صوتی گویشوران فارسی به همراه متن مرجع متناظر.

### مهم ترین ستون‌های دیتاست

- `client_id`: شناسه یکتای گویشور
- `path`: مسیر فایل صوتی در مخزن داده
- `audio`: داده صوتی خام (نرخ نمونه‌برداری ۱۶ کیلوهرتز)
- `sentence`: متن مرجع متناظر با فایل صوتی
- `up_votes` و `down_votes`: آرای مثبت و منفی به کیفیت نمونه
- `age`, `gender`, `accent`: اطلاعات جمعیت‌شناختی گویشور

### تفکیک داده‌ها (از پیش تعیین شده و مستقل از گویشور)

- آموزش (Train): ۲۹,۷۸۹ نمونه
- اعتبارسنجی (Validation): ۱۰,۶۷۶ نمونه
- آزمون (Test): ۱۰,۶۷۶ نمونه
- مجموع: ۵۱,۱۴۱ نمونه

تفکیک مستقل از گویشور (Speaker-Independent) است؛ یعنی گویشوران مجموعه آزمون با گویشوران مجموعه آموزش مشترک نیستند و مشکل نشت داده (Data Leakage) وجود ندارد.

# DATASET CREATION AND PREPARATION

## تولید خروجی‌های ASR و نرمال‌سازی داده

### تولید خروجی‌های اولیه



هر نمونه صوتی به‌طور جداگانه به دو مدل داده شد:

- Whisper-large-v3 (نمای اول): تنظیم زبان به فارسی، وظیفه رونویسی.
- MMS-1B-All (نمای دوم): تنظیم زبان هدف به کد fas.

### جزئیات فنی ...

- پردازش دسته‌ای روی GPU های T4 با اندازه ۸ (Batch Size = 8).
- استفاده از دقت نیمه‌دقیق (float16) برای تسریع استنتاج.
- ذخیره خروجی‌ها به‌همراه متن مرجع و شناسه‌ها در یک فایل CSV.
- مکانیزم نقطه بازرسی (Checkpoint) در فواصل ۱۰۰ نمونه ای برای ادامه پردازش در صورت قطع شدن.

### نرمال‌سازی متن (با کتابخانه Shekar)



داده‌های خام ASR و متن مرجع، حاوی تنوع نوشتاری هستند (نویسه‌های عربی، نیم‌فاصله، اعراب، علائم نگارشی ناهمسان).  
مؤلفه‌های Shekar:

- AlphabetNormalizer: یکسان‌سازی حروف الفبا و تبدیل نویسه‌های عربی به فارسی
- DigitNormalizer: یکسان‌سازی ارقام عربی و فارسی و انگلیسی
- PunctuationRemover: حذف علائم نگارشی
- RemoveDiacritics: حذف اعراب‌گذاری
- RepeatedLetterNormalizer: حذف تکرار حروف
- SpacingNormalizer: یکسان‌سازی فاصله‌ها

# DATASET CREATION AND PREPARATION

```
# =====  
# Load models  
# =====  
report("Loading Whisper-large-v3...")  
whisper_processor = WhisperProcessor.from_pretrained("openai/whisper-large-v3")  
whisper_model = WhisperForConditionalGeneration.from_pretrained(  
    "openai/whisper-large-v3"  
).to(DEVICE)  
if USE_FP16:  
    whisper_model = whisper_model.half()  
whisper_model.eval()  
whisper_model.generation_config.language = "fa"  
whisper_model.generation_config.task = "transcribe"  
  
report("Loading MMS-1B...")  
mms_processor = AutoProcessor.from_pretrained("facebook/mms-1b-all")  
mms_processor.tokenizer.set_target_lang("fas")  
mms_model = AutoModelForCTC.from_pretrained(  
    "facebook/mms-1b-all",  
    target_lang="fas"  
).to(DEVICE)  
if USE_FP16:  
    mms_model = mms_model.half()  
mms_model.eval()
```

# DATASET CREATION AND PREPARATION

## تولید خروجی‌های ASR و نرمال‌سازی داده

### اصلاح خط‌الرسم اشتباه در برچسب‌های دیتاست Common Voice



- استفاده از قواعد Regex به همراه لیست استثناها (به جای استفاده از LLM برای تصحیح خط‌الرسم به دلیل جلوگیری از توهم و تغییر معنایی کلمات عبارات و کاهش هزینه).
- مثال: «نتیجه‌گیری» ← «نتیجه‌گیری»، «شگفت‌آور» ← «شگفت‌آور»، «خانه‌های» ← «خانه‌های».

### پالایش داده‌های نامعتبر



- حذف نمونه‌هایی با CER/WER بسیار بالا.
- حذف نمونه‌هایی با خروجی خالی (یکی از دو مدل یا هر دو).
- حذف نمونه‌هایی با نسبت کاراکتر فارسی پایین.

• نتایج پالایش:

1. آموزش: ۲۹,۷۸۹ نمونه اولیه، ۶۵۷ حذف شده، ۲۹,۱۳۲ نمونه نهایی
2. اعتبارسنجی: ۱۰,۶۷۶ نمونه اولیه، ۳۴۹ حذف شده، ۱۰,۳۲۷ نمونه نهایی
3. آزمون: ۱۰,۶۷۶ نمونه اولیه، ۵۳۶ حذف شده، ۱۰,۱۴۰ نمونه نهایی



"مراتب", "جز", "طور", "  
 "جانب", "اندازه", "ناچا",  
 "اجبار", "زحمت", "ظاهر", "و",  
 "زودی", "کلی", "اثر", "عقبه", "

```
# 3.6) Safe whitelist
WHITELIST = {
    "بهینه‌ای": "بهینه‌ای",
    "فایده‌ای": "فایده‌ای",
    "ذره‌ای": "ذره‌ای",
    "جامعه‌ای": "جامعه‌ای",
    "عده‌ای": "عده‌ای",
    "اندازه‌ای": "اندازه‌ای",
    "بچه‌ای": "بچه‌ای",
    "غریبه‌ای": "غریبه‌ای",
    "قهوه‌ای": "قهوه‌ای",
    "ویژه‌ای": "ویژه‌ای",
    "اجاره‌ای": "اجاره‌ای",
    "اجازته‌ای": "اجازته‌ای",
    "چهره‌ای": "چهره‌ای",
    "خانه‌ای": "خانه‌ای",
    "کلبه‌ای": "کلبه‌ای",
    "برکه‌ای": "برکه‌ای",
    "دریاچه‌ای": "دریاچه‌ای",
    "رودخانه‌ای": "رودخانه‌ای",

```



# DATASET CREATION AND PREPARATION

|    |      |        |                                                           |                                                            |                                                         |
|----|------|--------|-----------------------------------------------------------|------------------------------------------------------------|---------------------------------------------------------|
| 48 | test | common | این واقعیت که شما به مردن می‌خندید شگفتآور است            | این واقعیت که شما به مردن می‌خندید شگفتآور است             | این واقعیت که شما به مردن می‌خندید شگفت‌آور است         |
| 49 | test | common | من گرسنه‌ام                                               | من گروه سنام                                               | من گرسنه هم                                             |
| 50 | test | common | از آنجا که من استفاده از نرم‌افزار غیراخلاقی را رد می‌کنم | از آنجا که من استفاده از نرم‌افزار دیر اخلاقی را رد می‌کنم | آنجا که من استفاده از نرم‌افزار طیر اخلاقی را رد می‌کنم |
| 51 | test | common | بعضی‌هاشون حتی از مارکز هم بی‌پدرترن باید بخونی           | بعضی‌هاشون حتی از مارکس هم بی‌پدرترن باید بخونید           | بعضیها شون حتی از مارکز هم بی‌پدرترمد باید بخونی        |
| 52 | test | common | اتومبیل هوا لغز شده                                       | اتوموبیل هوا لغز شده                                       | اتومبیل هوا لغظ شده                                     |
| 53 | test | common | زنگ در ژرف‌اندیشی او را مختل کرد                          | زنگ در جرف‌اندیشی او را مختل کرد                           | زنگ در ژرف‌اندیشی او را مختل کرد                        |
| 54 | test | common | زندانی چهل خود                                            | زندانی چه خود                                              | زندانی جل خود                                           |
| 55 | test | common | از بس هول هولکی رفتیم و اومدیم اصلا نفهمیدیم کی به کیه    | بس هولولکی رفتیم و اومدیم اصلا نفهم می‌دیم کی به کیه       | از بس حلحلکی رفتی معمدیم اصلا نفهمیدیم کیه              |
| 56 | test | common | بیمهای آتشنا شهر را دستخوش آتش‌سوزی گسترده‌ای کرد         | های آتش ساز شهر را دستخوش آتش‌سوزیه گسترده‌گرد             | های آدشساز شهر را دستخوش آدشسوزیه گسترده‌های کر         |
| 57 | test | common | اگر برای سر آقای برادر و بابام بیاد                       | اگر پرویزت رو روی برادر بابا بومید                         | اگر برای سر آقای برادر و بابام بیاد                     |
| 58 | test | common | و تاثیر خیلی مثبتی روی جان گذاشت                          | و تاثیر خیلی مصبتی روی جان گذاشت                           | و تاثیر خلی مسقطی روی جان نگذاشت                        |
| 59 | test | common | زیبایی شکوهمند هتل جدید                                   | زیبایی شکوکمند خوتل جدید                                   | زیبایی شکوخمند هتل جدید                                 |
| 60 | test | common | خوشه‌های زرین گندم                                        | خوشه‌های زرین نگندم                                        | خوشه‌های زرینگندم                                       |
| 61 | test | common | کشور گابن بزرگترین تولیدکننده منگنز در جهان است           | کشور گابون بزرگترین تولیدکننده منگنز در جهان است           | کشور گاپون بزرگترین تولیدکننده‌های منگنز در جهان است    |
| 62 | test | common | گلستان                                                    | گلستان                                                     | گلستان                                                  |
| 63 | test | common | جنگ‌افزارهای ساده                                         | جنگ افزارهای ساده                                          | جنگ اfdارهای ساده                                       |
| 64 | test | common | حاضری                                                     | حاضری                                                      | حاضری                                                   |
| 65 | test | common | کسی جلو نیاد خون جلو ششمو گرفته                           | کسی جلو نیاد خون جلو ششمو پرشده                            | کسی جلو نیاد خون جلو ششما گرفته                         |
| 66 | test | common | اشاعهی دانش                                               | اشراعی دانش                                                | اشاعهی دانش                                             |
| 67 | test | common | چرا چرند می‌گی حالت خوش نیست‌ها                           | چرا چرا هم می‌گی حالت خوش نیست‌ها                          | چرا چران می‌گی حالت خوش نیست آ                          |
| 68 | test | common | استالین رقیبان خود را یکی پس از دیگری نابود کرد           | استالین رقیبان خود را یکی پس از دیگری نابود کرد            | اسالین رقیمان خود را یکی پس از دیگری نابود کرد          |
| 69 | test | common | مردم به او به چشم یک قهرمان می‌نگرند                      | مردم به او به چشم یک قهرمان می‌نگرند                       | مردم به او به چشم یک قهرمان می‌نگرند                    |
| 70 | test | common | اشتباهات باید فوری برطرف شوند                             | اشتباهات باید فوری برطرف شوند                              | اشتباعات باید فوری بر طرف شوند                          |
| 71 | test | common | گوشت‌های قایم شد تا ببیند چه کسی ان را از مسیر برمی‌دارد  | های قایم شد تا ببیند چه کسی آن‌را از مسیر برمی‌دارد        | های غایم شد تا ببیند چه کسی آن‌را از مسیر برمی‌دارد     |
| 72 | test | common | ز بعد هفتاد نوروز یک برفی افتاد                           | ز بعد هفتاد نوروز یک برفی افتاد                            | ز بعد هفتاد نوروز یک برفی افتاد                         |
| 73 | test | common | جرم قانونی                                                | جرم قانونی                                                 | جرم قانونی                                              |
| 74 | test | common | او می‌کوشد بر اعتیاد خود به الکل فایق آید                 | او می‌کشد بر اعتیاد خود به الکل فایق آید                   | او می‌کوشد بر اعتیاد خود به الکل فایغ آید               |
| 75 | test | common | تخفیف قیمت                                                | خواهید را دیمت                                             | تختیر قیمت                                              |
| 76 | test | common | سهراب پیدا شد                                             | سه راب بی در شد                                            | سوراب پیدار شد                                          |
| 77 | test | common | دولت از حمایت مردم برخوردار است                           | دولت از حمایت مردم برخوردار است                            | دولت از حمایت مردم برخوردار است                         |
| 78 | test | common | زمین‌شناسی یا دانش پوستهی کرهی زمین                       | زمین‌شناسی و دانش پوستهی کربزنی                            | زمین‌شناسی یا دانش پوسته‌ای کوری زمین                   |
| 79 | test | common | مدافعه کردن                                               | مدار فریکار در                                             | مدافعه کردن                                             |
| 80 | test | common | او همه گونه اطلاعات کم و بیش مهم را کسب کرد               | او همه گونه اطلاعات کم و بیش مهم را کسب کرد                | او همگونه اطلاعات کمابیش مهم را کسب کرد                 |
| 81 | test | common | اگر اتفاق بدی بیفتد تو جوابگو خواهی بود                   | اگر اتفاق بدی بیفتد تو جوابگو خواهی بود                    | اگر اتفاق بدی بیفتد تو جوابگو خواهی بود                 |
| 82 | test | common | تانک بنزین                                                | تانک بنزین                                                 | تانک بنزین                                              |
| 83 | test | common | نخل قامت                                                  | نخل قامت                                                   | نخل قامت                                                |



# DATASET CREATION AND PREPARATION

[illegible]

# MODEL IMPLEMENTATION AND TRAINING

💡 مدل کاراکتری در برابر زیرواژه‌ای

سوال:

واحد پردازش در مدل تصحیح چه باشد؟ کاراکتر یا زیرواژه؟

مدل کاراکتری:

منطق:

هر کاراکتر یک واحد مستقل در نظر گرفته می‌شود. مدل باید در هر موقعیت، تصمیم بگیرد که کدام کاراکتر از کدام نما را انتخاب کند.

مزیت:

• خطاهای ASR روی فارسی اغلب موضعی و کاراکتری هستند (هم‌آوایی، فاصله‌گذاری).

• مدل می‌تواند در سطح هر کاراکتر تصمیم مستقل بگیرد.

• دیکشنری کوچک و قابل مدیریت.

نقطه ضعف:

• طول دنباله‌ها زیاد می‌شود و محاسبات سنگین‌تر است.

• ممکن است کلماتی تولید شود که نادرست اند مانند کلمه حقوق به جای حقوق

مدل زیرواژه‌ای:

منطق:

استفاده از قطعه‌بندی زیرواژه‌ای (SentencePiece) برای کاهش طول دنباله‌ها.

مزیت:


• زیرواژه‌های اشتباه تولیدشده، به دلیل حضور نداشتن در واژگان مدل، ناگزیر به شکل صحیح‌تری بازنویسی می‌شدند.

• کاهش طول دنباله منجر به کاهش زمان آموزش می‌شود.

نقطه ضعف:

• تولید نادرست یک زیرواژه، چندین کاراکتر را همزمان تحت تأثیر قرار می‌دهد و اثر تجمعی بزرگ‌تری در CER ایجاد می‌کند.

• دیکشنری زیرواژه‌ای با وجود طول بیشتر برای پوشش کامل واژگان فارسی کافی نیست.





# MODEL IMPLEMENTATION AND TRAINING

💡 مدل کاراکتری در برابر زیرواژه‌ای

مدل زیرواژه‌ای:

مدل کاراکتری:



شکل ۵-۲: توزیع خطاهای مدل زیرواژه‌ای در چهار پل: توزیع CER، توزیع خطاهای سطح کلمه، عملیات ویرایش در سطح کاراکتر، و رابطه CER با طول جمله.

شکل ۵-۵: توزیع خطاهای مدل کاراکتری با کاراکتر تهی. مقایسه این نمودار با شکل ۵-۲ نشان می‌دهد که مدل کاراکتری خطاهای کمتری در همه دسته‌ها تولید کرده است.



# MODEL IMPLEMENTATION AND TRAINING

💡: آموزش هم‌ترازی کاراکتری دو خروجی ASR

## ضرورت هم‌ترازی:

دو خروجی ASR می‌توانند طول‌های متفاوت و ساختار ناهمسان داشته باشند. برای مقایسه‌ی حرف‌به‌حرف، باید آن‌ها را هم‌طول کرد.

ابزار: الگوریتم فاصله‌ی لونشتاین (Levenshtein Distance) بر پایه‌ی برنامه‌ریزی پویا.

## راهبرد اول - هم‌ترازی با کاراکتر تهی (∅): منطق:


در موقعیت‌هایی که یک کاراکتر در یکی از دنباله‌ها وجود دارد و در دنباله‌ی دیگر متناظر ندارد، یک نماد تهی در محل خالی درج می‌شود.

### مثال:

- Whisper: «خواب»
- MMS: «خاب»
- هم‌ترازی با تهی: «خواب» و «خ∅اب»

### مزیت:

- اطلاعات تمایزی موجود در تفاوت دو نما حفظ می‌شود.
- مدل می‌تواند یاد بگیرد کدام نما در آن موقعیت قابل‌اعتمادتر است.
- نماد تهی قابل‌مشاهده باقی می‌ماند و مدل خودش تصمیم می‌گیرد که آن را نادیده بگیرد یا خیر.



## راهبرد دوم - هم‌ترازی با جایگزینی از رشته طولانی‌تر: منطق:

به جای درج نماد تهی، جای خالی در دنباله‌ی کوتاه‌تر با کاراکتر متناظر در دنباله‌ی طولانی‌تر جایگزین می‌شود.

### مثال:

- Whisper: «خواب»
- MMS: «خاب»
- هم‌ترازی با جایگزینی: «خواب» و «خواب»

### ایراد:

- اگر یک مدل کاراکتر اشتباه اضافی تولید کرده باشد، این راهبرد همان خطا را به نمای دیگر تحمیل می‌کند. در نتیجه، هر دو خروجی شامل کاراکتر اشتباه اضافی می‌شوند.
- اطلاعات تمایزی بین دو نما از بین می‌رود ولی در مواردی با اصلاح خروجی نادرست (مثل تبدیل خاب به خواب) به بهبود خوانایی خروجی نهایی مدل کمک می‌کند.

# MODEL IMPLEMENTATION AND TRAINING

با توجه به نکات سه اسلاید قبل نهایتاً مدل با دیکشنری کاراکتری و روش همترازی با کاراکتر تهی (Ø) به عنوان مدل اصلی انتخاب شد. 

جدول ۵-۶: مقایسه جامع همه مدل‌ها روی مجموعه تست

| مدل                       | CER    | WER    | $\Delta$ CER از Whisper | $\Delta$ CER از MMS |
|---------------------------|--------|--------|-------------------------|---------------------|
| Whisper خام               | ۰.۰۹۸۰ | ۰.۳۲۸۳ | —                       | ٪۲۷۸+               |
| MMS خام                   | ۰.۰۷۰۲ | ۰.۲۸۴۱ | ٪۲۷۸-                   | —                   |
| زیرواژه‌ای                | ۰.۱۸۹۷ | ۰.۳۹۹۸ | ٪۹۱۷+                   | ۰/۱۱۹۵+             |
| کاراکتری + کاراکتر تهی    | ۰.۰۷۲۶ | ۰.۲۸۵۵ | ٪۲۵۴-                   | ٪۰۲۴+               |
| کاراکتری + رشته طولانی‌تر | ۰.۰۸۳۰ | ۰.۳۱۳۰ | ٪۱۵۰-                   | ٪۱۲۸+               |



# MODEL IMPLEMENTATION AND TRAINING

|    |                                 |                                  |                                 |                                   |
|----|---------------------------------|----------------------------------|---------------------------------|-----------------------------------|
| 62 | گلستان                          | گلستان                           | گلستان                          | گلستان                            |
| 63 | جنگ افزار های ساده              | جنگ افزار های ساده               | جنگ افزار های ساده              | جنگ افزار های ساده                |
| 64 | حاضری                           | حاضری                            | حاضری                           | حاضری                             |
| 65 | کسی جلو نیاد خون جلو ششمو گرفته | کسی جلو نیاد خون جلو ششمو پر شده | کسی جلو نیاد خون جلو ششما گرفته | کسی جلو نیاد خون جلو شششم گرفته ی |
| 66 | اشاعه ی دانش                    | اشراعی دانش                      | اشاعه ی دانش                    | اشععه                             |

|     |                                 |                                   |                                 |                               |
|-----|---------------------------------|-----------------------------------|---------------------------------|-------------------------------|
| 100 | مناظره را طول دادند             | مناظره را طول دادند               | مناظره را طول دادند             | مناظره را طول دادند           |
| 101 | آن ها دارند اتاق را رنگ می زنند | آن ها دارند اون ها را رنگ می زنند | آن ها دارند اتاق را رنگ می زنند | آن ها دارند او را را می زنند  |
| 102 | او پولم را زد                   | او پولم را زد                     | او پولم را زد                   | او پولم را زد                 |
| 103 | ذرات بنیادی اتم                 | ذرات بنیادی ا طول                 | ذرات بنیادی اتم                 | ذرات بنیادی اتمی              |
| 104 | صدای گوشخراش شیپور ها بلند شد   | صدای گوشخراش شیپور ها بلند شد     | صدای گوشخراش شیپور ها بلند شد   | صدای گوشخراش شیپور ها بلند شد |

# MODEL IMPLEMENTATION AND TRAINING

معماری مدل: رمزگذار BiLSTM و رمزگشای توجهی

## LSTM چیست؟

یک نوع شبکه‌ی عصبی بازگشتی (RNN) که برای حل مشکل محو یا انفجار گرادیان در RNN‌های ساده طراحی شده است. LSTM با معرفی یک **سلول حافظه** و سه **گیت** می‌تواند وابستگی‌های بلندمدت را بهتر حفظ کند.

## BiLSTM چیست؟

از دو LSTM مستقل تشکیل شده است:

- یکی از چپ به راست (Forward)
- دیگری از راست به چپ (Backward)

خروجی نهایی BiLSTM از الحاق خروجی این دو LSTM به دست می‌آید. بنابراین، بُعد خروجی BiLSTM دو برابر بُعد پنهان یک LSTM تک‌جهته است.

## چرا BiLSTM برای این پروژه؟

در وظیفه‌ی تصحیح متن، تعیین کاراکتر صحیح در هر موقعیت نیازمند **در نظر گرفتن زمینه از هر دو جهت چپ و راست** است. مثلاً برای تشخیص اینکه «ز» یا «ذ» در یک کلمه صحیح است، مدل باید کل کلمه را ببیند، نه فقط کاراکترهای قبل را.

## رمزگذار مشترک (Shared Encoder)

هر دو نما از یک رمزگذار مشترک عبور می‌کنند. ابتدا نمادهای هم‌تراز شده از دو خروجی ASR **تعبیه (Embed)** شده و سپس **به صورت الحاقی** به رمزگذار داده می‌شوند.

## مزیت:

- کاهش پارامترهای مدل.
- اجازه می‌دهد اطلاعات دو نما با یکدیگر تلفیق شوند.

# MODEL IMPLEMENTATION AND TRAINING

معماری مدل: رمزگذار BiLSTM و رمزگشای توجهی

رمزگشا چیست؟

یک LSTM یک جهت که متن نهایی را کاراکتر به کاراکتر تولید می‌کند.

مکانیزم توجه (Attention):

در هر گام رمزگشایی، به جای اتکا به یک بردار زمینه‌ی ثابت، رمزگشا به تمام حالت‌های پنهان رمزگذار توجه می‌کند و بردار زمینه را به صورت مجموع وزن دار از آن‌ها محاسبه می‌کند.

نوع توجه:


از مکانیزم توجه Bahdanau (Additive Attention) استفاده شده است. در این نوع، وزن‌های توجه از طریق یک شبکه‌ی کوچک با تابع فعال‌سازی tanh محاسبه می‌شوند.

چرا توجه؟

- رمزگشا می‌تواند در هر گام به بخش‌های مرتبط ورودی تمرکز کند.
- برای تصحیح کاراکتری، این یعنی مدل می‌تواند به کاراکترهای همسایه و زمینه‌ی کلمه توجه کند.

# MODEL IMPLEMENTATION AND TRAINING

معماری مدل: رمزگذار BiLSTM و رمزگشای توجهی



知乎: 天雨粟  
知乎专栏: 机器学习  
GitHub: NELSONZHAO

知乎 @天雨粟




Figure 1: Encoder-Decoder architecture with attention module. Section numbers reference experiments corresponding to the components.

# MODEL IMPLEMENTATION AND TRAINING

## Teacher Forcing و نرخ یادگیری

### Teacher Forcing چیست؟

در آموزش مدل‌های دنباله‌به‌دنباله (Seq2Seq)، در هر گام رمزگشایی، به جای استفاده از خروجی رمزگشا در گام قبل، از توکن صحیح متن مرجع استفاده می‌شود.

### چرا لازم است؟

- بدون آن، به این دلیل که مدل در مراحل اولیه‌ی آموزش، خروجی‌های نادرست تولید می‌کند و اگر خروجی‌های نادرست را به عنوان توکن بعدی به رمزگشا بدهیم، این نادرستی‌ها به گام‌های بعدی منتقل می‌شود.
- Teacher Forcing همگرایی را تسریع می‌کند.

### چالش:

- اگر نرخ Teacher Forcing خیلی زیاد باشد، مدل به توکن‌های صحیح وابسته می‌شود و در زمان استنتاج افت می‌کند (انحراف آموزش-استنتاج).
- اگر نرخ Teacher Forcing خیلی کم باشد، آموزش کند و ناپایدار می‌شود.

### راه حل:

نرخ Teacher Forcing در ابتدای آموزش زیاد است و به تدریج در طول آموزش کاهش می‌یابد. در این پروژه از کاهش خطی و سیگموئیدی استفاده شد.

### نرخ یادگیری:

نرخ یادگیری نسبتاً پایین انتخاب شد تا مدل به سرعت دچار بیش‌برازش نشود و آموزش پایدار بماند.



# MODEL IMPLEMENTATION AND TRAINING

## Teacher Forcing و نرخ یادگیری

روش نخست — کاهش خطی. در این روش، نرخ Teacher Forcing به صورت خطی از مقدار حداکثر به مقدار حداقل کاهش می یابد:

$$TF(e) = \max(TF_{\max} - (e - 1) \cdot TF_{\text{decay}}, TF_{\min}) \quad (۱-۴)$$

$$TF(e) = TF_{\min} + (TF_{\max} - TF_{\min}) \cdot \frac{1}{1 + e^{\lambda \cdot (e - e_0)}} \quad (۲-۴)$$

این روش در مدل با دیشکری زیرواژه ای استفاده شده است. مزیت این روش، کاهش نرم و تدریجی در ابتدا و انتها، و کاهش سریع تر در میانه آموزش است که با مرحله حساس یادگیری مدل هماهنگ است. این روش باعث می شود در ابتدای آموزش که مدل به راهنمایی بیشتری نیاز دارد، نرخ Teacher Forcing بالا بماند و در میانه آموزش که مدل شروع به یادگیری الگوهای مستقل می کند، نرخ با شیب تندتری کاهش یابد.

# MODEL IMPLEMENTATION AND TRAINING

## مکانیزم ادغام گیت‌دار (Gated Fusion)

### ایده‌ی اصلی

این ماژول بین رمزگذار و رمزگشا قرار می‌گیرد و به واسطه آن دو بردار بازنمایی برای هر نما از خروجی رمزگذار استخراج می‌شود. مکانیزم گیت‌دار تصمیم می‌گیرد که در هر موقعیت، به کدام نما بیشتر اتکا شود.

### منطق گیت:

گیت‌ها به صورت باقی‌مانده (Residual) عمل می‌کنند: اطلاعات نمای مقابل، پس از عبور از تابع  $\tanh$  و ضرب در گیت، به صورت یک جمله‌ی افزودنی روی نمای اصلی سوار می‌شود.

### فرمول اصلی مقاله (Residual Modulator)

گام ۱: استخراج دو جریان از رمزگذار  
از خروجی رمزگذار، دو جریان  $vt(1)$  و  $vt(2)$  با لایه‌های خطی استخراج می‌شوند.  
گام ۲: محاسبه‌ی گیت‌های متقاطع  
گیت‌های  $g12$  و  $g21$  با تابع سیگموئید محاسبه می‌شوند. این گیت‌ها در بازه‌ی صفر تا یک قرار دارند.  
گام ۳: تعدیل با باقی‌مانده  
بازنمایی تعدیل‌شده‌ی هر نما، مجموع نمای اصلی و جمله‌ی گیت‌دار از نمای مقابل است.  
تفسیر:

- اگر گیت نزدیک صفر باشد، نمای اصلی حفظ می‌شود.
- اگر گیت نزدیک یک باشد، اطلاعات نمای مقابل استفاده می‌شود.

# MODEL IMPLEMENTATION AND TRAINING

مکانیزم ادغام گیت‌دار (Gated Fusion)

فرمول اصلی مقاله (Residual Modulator)

در مقاله مرجع، ابتدا دو جریان  $\mathbf{v}_t^{(1)}$  و  $\mathbf{v}_t^{(2)}$  با استفاده از لایه‌های خطی از بردار پنهان مشترک  $\mathbf{h}_t$  که خروجی رمزگذار است، استخراج می‌شوند و سپس گیت‌های متقاطع به‌صورت زیر محاسبه می‌شوند:

$$\mathbf{g}_{12,t} = \sigma \left( W_{12} [\mathbf{v}_t^{(1)}; \mathbf{v}_t^{(2)}] \right) \in \mathbb{R}^H \quad (۳-۶)$$

$$\mathbf{g}_{21,t} = \sigma \left( W_{21} [\mathbf{v}_t^{(2)}; \mathbf{v}_t^{(1)}] \right) \in \mathbb{R}^H \quad (۳-۷)$$

و بازنمایی‌های تعدیل‌شده به‌صورت زیر محاسبه می‌شوند:

$$\hat{\mathbf{h}}_t^{(1)} = \mathbf{v}_t^{(1)} + \mathbf{g}_{12,t} \odot \tanh(\mathbf{v}_t^{(2)}) \quad (۳-۸)$$

$$\hat{\mathbf{h}}_t^{(2)} = \mathbf{v}_t^{(2)} + \mathbf{g}_{21,t} \odot \tanh(\mathbf{v}_t^{(1)}) \quad (۳-۹)$$

$$\hat{\mathbf{h}}_t = [\hat{\mathbf{h}}_t^{(1)}; \hat{\mathbf{h}}_t^{(2)}] \in \mathbb{R}^{2H} \quad (۳-۱۰)$$

# MODEL IMPLEMENTATION AND TRAINING

مکانیزم ادغام گیت دار (Gated Fusion)

فرمول پیاده سازی شده در این پروژه (ترکیب محدب)

تفاوت اول - افزودن Layer Normalization:

افزودن Layer Normalization پس از لایه های خطی، دو جریان را به یک مقیاس مشترک نرمال سازی می کند و تضمین می کند که جمله ی گیت دار از نظر مقیاس با نمای اصلی قابل مقایسه باشد.

تفاوت دوم - جایگزینی اتصال باقی مانده با ترکیب محدب:

در فرمول مقاله، جمله ی گیت دار به نمای اصلی اضافه می شود. در پیاده سازی این پروژه، از ترکیب محدب استفاده شد. مزیت ترکیب محدب:

- خروجی همواره در فضای دو نما باقی می ماند.
- تفسیر گیت ساده تر است: گیت مستقیماً نشان دهنده ی وزن هر نما است.
- نمای اصلی همواره در فرمول وجود ندارد و اگر این نما کاملاً نادرست باشد گیت ها می توانند اثر آن را حذف کنند.

# MODEL IMPLEMENTATION AND TRAINING

مکانیزم ادغام گیت‌دار (Gated Fusion)

فرمول پیاده‌سازی شده در این پروژه (ترکیب محدب)

در پیاده‌سازی این پروژه، فرمول‌ها به صورت زیر بازنویسی شدند:

$$\mathbf{v}_t^{(1)} = \text{LN}(W_1 \mathbf{h}_t + b_1), \quad \mathbf{v}_t^{(2)} = \text{LN}(W_2 \mathbf{h}_t + b_2) \quad (۱۱-۳)$$

$$\mathbf{g}_{12,t} = \sigma\left(W_{12}[\mathbf{v}_t^{(1)}; \mathbf{v}_t^{(2)}] + b_{12}\right) \quad (۱۲-۳)$$

$$\mathbf{g}_{21,t} = \sigma\left(W_{21}[\mathbf{v}_t^{(2)}; \mathbf{v}_t^{(1)}] + b_{21}\right) \quad (۱۳-۳)$$

$$\hat{\mathbf{h}}_t^{(1)} = (1 - \mathbf{g}_{12,t}) \odot \mathbf{v}_t^{(1)} + \mathbf{g}_{12,t} \odot \mathbf{v}_t^{(2)} \quad (۱۴-۳)$$

$$\hat{\mathbf{h}}_t^{(2)} = \mathbf{g}_{21,t} \odot \mathbf{v}_t^{(1)} + (1 - \mathbf{g}_{21,t}) \odot \mathbf{v}_t^{(2)} \quad (۱۵-۳)$$


$$\hat{\mathbf{h}}_t = [\hat{\mathbf{h}}_t^{(1)}; \hat{\mathbf{h}}_t^{(2)}] \in \mathbb{R}^{2H} \quad (۱۶-۳)$$

که در آن  $\text{LN}(\cdot)$  عملگر Layer Normalization،  $\sigma$  تابع سیگموئید و  $\odot$  ضرب عنصر به عنصر است.




# MODEL IMPLEMENTATION AND TRAINING

مشکلی که حین آموزش مدل‌ها مشاهده شد این بود که مقادیر گیت‌ها تنها در یک بازه کوچک  $[0.45, 0.55]$  نوسان می‌کند. درحالی که مقدار گیت‌ها خروجی تابع سیگموید هستند و می‌تواند مقادیری در تمام بازه  $[0, 1]$  داشته باشد. بنابراین از روش‌هایی برای افزایش واریانس مقادیر گیت‌ها و پویایی آن‌ها استفاده شد که در ادامه بیان می‌شوند.



شکل ۵-۱: نمودار گیت‌های مدل زیرواژه‌ای. نمودار سمت چپ توزیع مقادیر گیت را نشان می‌دهد و نمودار سمت راست تغییرات میانگین گیت با موقعیت کاراکتر در جمله را نمایش می‌دهد.



شکل ۵-۴: نمودار گیت‌های مدل کاراکتری با کاراکتر تهی. در این مدل، توزیع گیت‌ها پهن‌تر از مدل زیرواژه‌ای است که نشان‌دهنده پویایی بیشتر مکانیزم گیت است.

# MODEL IMPLEMENTATION AND TRAINING

## فروپاشی گیت و تلاش برای پویایی

**مشاهده‌ی اولیه: فروپاشی گیت (Gate Collapse)**  
گیت‌ها به جای یادگیری تصمیمات پویا و وابسته به محتوا، به یک مقدار تقریباً ثابت همگرا می‌شوند.

### تلاش‌های انجام‌شده برای افزایش پویایی ۱. Gate Variance Regularization:

افزودن جمله‌ای به تابع هزینه که واریانس گیت‌ها در طول زمان را به‌عنوان پاداش در نظر می‌گیرد.  
نتیجه: واریانس گیت افزایش یافت اما منجر به کمی افت عملکرد شد.

### ۲. Scaled Sigmoid:

فشرده‌سازی خروجی گیت در بازه‌ی باریک‌تر برای جلوگیری از اشباع سیگموئید.  
نتیجه: بهبود معناداری حاصل نشد.

### ۳. حذف Layer Normalization:

بازگشت به فرمول اصلی مقاله.  
نتیجه: بهبود معناداری حاصل نشد.

### ۴. Dropout حسی کامل و جزئی:

گسترش حالت‌ها برای تقویت استقلال از نما.  
نتیجه: بهبود معناداری حاصل نشد.

# MODEL IMPLEMENTATION AND TRAINING

## فروپاشی گیت و تلاش برای پویایی

فرمول‌بندی ریاضی: تابع هزینه کل به صورت زیر تعریف می‌شود:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{CE}} - \lambda \cdot (\text{Var}(g_{12}) + \text{Var}(g_{21})) \quad (۴-۵)$$

محاسبه واریانس گیت: واریانس هر گیت به صورت زیر محاسبه می‌شود:

$$\text{Var}(g_{12}) = \frac{1}{B \cdot H} \sum_{b=1}^B \sum_{h=1}^H \frac{1}{T} \sum_{t=1}^T \left( g_{12,t}^{(b,h)} - \bar{g}_{12}^{(b,h)} \right)^2 \quad (۵-۵)$$

الف) **Scaled Sigmoid**: به جای استفاده از تابع سیگموئید خالص که خروجی آن در بازه (0, 1) قرار می‌گیرد،

از یک نسخه مقیاس شده استفاده شد:



$$g_{12} = \alpha \cdot \sigma(W_{12}[v_1; v_2]) + \beta \quad (۹-۵)$$

که در آن  $\alpha = 0.8$  و  $\beta = 0.1$ . این تغییر، گیت را در بازه باریک‌تر [0.1, 0.9] نگه می‌دارد و از اشباع شدید

در نواحی ۰ و ۱ جلوگیری می‌کند.

# MODEL IMPLEMENTATION AND TRAINING

فروپاشی گیت و تلاش برای پویایی



جدول ۵-۶: مقایسه جامع همه مدل‌ها روی مجموعه تست

| مدل                       | CER    | WER    | $\Delta$ CER از Whisper | $\Delta$ CER از MMS |
|---------------------------|--------|--------|-------------------------|---------------------|
| Whisper خام               | ۰.۰۹۸۰ | ۰.۳۲۸۳ | —                       | ٪۲۷۸+               |
| MMS خام                   | ۰.۰۷۰۲ | ۰.۲۸۴۱ | ٪۲۷۸-                   | —                   |
| زیرواژه‌ای                | ۰.۱۸۹۷ | ۰.۳۹۹۸ | ٪۹۱۷+                   | ۰/۱۱۹۵+             |
| کاراکتری + کاراکتر تهی    | ۰.۰۷۲۶ | ۰.۲۸۵۵ | ٪۲۵۴-                   | ٪۰۲۴+               |
| کاراکتری + رشته طولانی‌تر | ۰.۰۸۳۰ | ۰.۳۱۳۰ | ٪۱۵۰-                   | ٪۱۲۸+               |
| Paper + Gate Var          | ۰.۰۷۷۴ | ۰.۳۰۲۶ | ٪۲۰۶-                   | ٪۰۷۲+               |
| Convex + Gate Var         | ۰.۰۷۸۶ | ۰.۳۰۶۲ | ٪۱۹۴-                   | ٪۰۸۴+               |

# ANALYSIS

همانطور که در نمودار گیت‌ها در اسلاید قبل که مربوط به مدلی با فرمول گیت مقاله مرجع همراه با مکانیزم‌های افزایش پویایی گیت‌هاست، مشهود است **واریانس گیت‌ها افزایش یافته است ولی خطای CER و WER مدل بهبود نیافته است**. هم‌چنین گیت‌ها هنوز هم در کل بازه [0.1,0.9] پراکنده نشده‌اند بلکه در ابتدای و انتهای بازه متمرکز هستند.

به نظر می‌رسید مکانیزم ترکیب، عملاً به یک میانگین‌گیری ساده با وزن ثابت تبدیل شده است. گیت هیچ اطلاعاتی درباره‌ی محتوا منتقل نمی‌کند.

این مشاهده باعث شد با محاسبه همبستگی بین مقادیر گیت‌ها و موقعیت کاراکتر در جمله، درستی پیش‌بینی مدل Whisper و درستی پیش‌بینی مدل MMS به دنبال علت این پدیده باشیم که در آینده بیان می‌شود.

جدول ۵-۸: همبستگی درستی نماها با موقعیت

| متغیر         | همبستگی با موقعیت |
|---------------|-------------------|
| درستی MMS     | -۰/۳۴۴۸           |
| درستی Whisper | -۰/۳۳۴۳           |

جدول ۵-۷: همبستگی خام گیت با موقعیت و درستی نماها

| متغیر          | همبستگی با $g_{12}$ | p-value   | وضعیت   |
|----------------|---------------------|-----------|---------|
| موقعیت کاراکتر | +۰/۷۷۴۴             | $< 0.001$ | معنادار |
| درستی MMS      | -۰/۲۹۷۰             | $< 0.001$ | معنادار |
| درستی Whisper  | -۰/۲۹۳۰             | $< 0.001$ | معنادار |

جدول ۵-۹: همبستگی جزئی گیت با درستی نما (کنترل موقعیت)

| متغیر                        | همبستگی خام | همبستگی جزئی | کاهش   |
|------------------------------|-------------|--------------|--------|
| درستی MMS (کنترل موقعیت)     | -۰/۲۹۷۰     | -۵۰۴٪        | ۸۳/۰۳٪ |
| درستی Whisper (کنترل موقعیت) | -۰/۲۹۳۰     | -۵۷۳٪        | ۸۰/۴۴٪ |



# ANALYSIS

آیا گیت بر اساس محتوا (کدام نما در آن موقعیت درست است) تصمیم می‌گیرد یا بر اساس موقعیت کاراکتر در جمله؟

- با محاسبه‌ی همبستگی روی ۵۷,۹۵۸ نقطه داده (همه‌ی کاراکترهای مجموعه‌ی اعتبارسنجی) نتایج ذکر شده در اسلاید قبل مشاهده شد.
- در نگاه اول، این نتایج نشان می‌دهد که گیت با هر سه متغیر موقعیت کاراکتر، درستی Whisper و درستی MMS در آن موقعیت همبستگی دارد.
- اما این تفسیر به دلیل وجود همبستگی خطی بین موقعیت کاراکتر و درستی نماها در آن موقعیت نادرست است. زیرا درستی هر دو نما (MMS و Whisper) همبستگی منفی معنادار حدود -۰.۳۴ با موقعیت دارد.
- علت این همبستگی منفی این است که درستی پیش‌بینی هر دو مدل ASR با طولانی شدن جمله بدتر می‌شود.
- بنابراین از آنجا که هم گیت با موقعیت همبستگی دارد (+۰.۷۷) و هم درستی نماها با موقعیت همبستگی دارند (-۰.۳۴)، یک همبستگی کاذب بین گیت و درستی نماها ایجاد می‌شود.
- با محاسبه‌ی همبستگی جزئی بین گیت و درستی نما، پس از حذف اثر موقعیت، همبستگی گیت با درستی نما از حدود -۰.۲۹ به -۰.۰۵ کاهش یافت. همبستگی جزئی -۰.۰۵ در حد نویز آماری است.
- بنابراین گیت هیچ سیگنال محتوایی مستقلی را یاد نگرفته است.



# ANALYSIS

علت بنیادی شکست ای معماری روی زبان فارسی: ماهیت خطاها و ظرفیت اطلاعاتی مدل

گیت به Shortcut Learning پناه برد...

Shortcut Learning چیست؟

مدل در مسیر کمینه سازی loss، ابتدا ساده ترین راه حل را کشف می کند. پس از آن، گرادیان ها در ناحیه ی راه حل محتوایی (که پیچیده تر است) بسیار کوچک می شوند و مدل هرگز به آن سمت نمی رود.

در این پروژه:

مدل به جای یادگیری الگوهای محتوایی، به یک heuristic وابسته به موقعیت پناه برده است. این راه حل ساده است و می گوید در ابتدای جمله کمی بیش تر از اطلاعات نمای مقابل بهره ببر و در انتهای بیش تر به خودت اتکا کن.

سوال کلیدی این است که چرا مدل نتوانست الگوهای محتوایی را یاد بگیرد؟

# ANALYSIS

علت بنیادی شکست ای معماری روی زبان فارسی: ماهیت خطاها و ظرفیت اطلاعاتی مدل

دلیل اول: خطاهای فارسی به موقعیت کاراکتر بستگی ندارند.  
ماهیت خطاهای فارسی:

- خطاهای هم‌آوایی (ذ/ز/ض/ظ، س/ص/ث، ت/ط، ه/ح) در فارسی الگوی موقعیتی ندارند.
- هر نویسه ممکن است در هر موقعیتی از هر کلمه‌ای اشتباه شود و این خطاها در کل طول جمله پخش شده‌اند.
- خطاها واژگانی و حافظه‌ای هستند.
- مثال: تمایز «حضرت» از «حذرت» یک امر حافظه‌ای است.
- تمایز این نویسه‌ها صرفاً از روی شکل نوشتاری ممکن است، نه از ویژگی‌های صوتی یا موقعیت.
- حتی اگر گیت به محتوای کلمه دسترسی داشته باشد، نمی‌تواند از روی «ز» یا «ذ» در یک موقعیت خاص، بفهمد کدام درست است، مگر اینکه املاي کل کلمات را حفظ کرده باشد.
- یادگیری این الگوها نیازمند ظرفیت اطلاعاتی بسیار بالاتر است.

در راجستانی (دواناگری):

- خطاها محلی و موقعیتی هستند.
- مثال: جایگاه اعراب (matra)، مرز کلمه، آسپیراسیون.
- این خطاها الگوهای تکرارشونده و قابل یادگیری دارند.
- یک مدل با ظرفیت محدود می‌تواند این الگوها را یاد بگیرد.

# ANALYSIS

علت بنیادی شکست ای معماری روی زبان فارسی: ماهیت خطاها و ظرفیت اطلاعاتی مدل

دلیل دوم: کران اطلاعاتی ظرفیت مدل

**سوال:** آیا مدل کوچک فعلی (با ۱۲۸ واحد پنهان در رمزگذار و رمزگشا) از نظر اطلاعاتی ظرفیت حل این مسئله را دارد؟

یک محاسبه اجمالی به صورت زیر نشان می‌دهد:

ظرفیت مؤثر BiLSTM:

- یک BiLSTM با ۱۲۸ واحد پنهان در هر جهت، در هر گام زمانی یک بردار ۲۵۶ بعدی تولید می‌کند.
- اگر هر مؤلفه حدود ۱۰ بیت اطلاعات کدگذاری کند، ظرفیت کل حدود ۲۵۶۰ بیت است.

اطلاعات لازم برای نگارش صحیح واژگان فارسی:

- تعداد کلمات رایج: حدود ۵,۰۰۰
- اندازه الفبای فارسی: حدود ۳۲ حرف
- میانگین طول یک کلمه: حدود ۵ حرف
- اطلاعات لازم برای کدگذاری نگارش صحیح یک کلمه: حدود ۲۵ بیت
- اطلاعات لازم برای کدگذاری نگارش صحیح تمام واژگان: حدود ۱۲۵۰۰۰ بیت

**نتیجه:**

اطلاعات لازم برای یادگیری نگارش صحیح واژگان فارسی، حدود ۵۰ برابر ظرفیت مدل کوچک فعلی با حدود دو میلیون و پانصد هزار پارامتر است.

# CONCLUSION

درس‌های آموخته شده از این پروژه 

«موفقیت یک معماری در یک زبان یا در یک مسئله، الزاما به معنای موفقیت آن در زبان دیگر یا مسئله دیگر نیست.»

این بینش، هم برای پژوهشگران ASR و هم برای طراحان معماری‌های چندزبانه، اهمیت بنیادی دارد. طراحی سیستم‌های چندزبانه باید آگاه از تفاوت‌های ساختاری زبان‌های هدف باشد، نه مبتنی بر فرض تعمیم‌پذیری جهانی.

# FUTURE WORKS

## ۱. ترکیب دو نما با استفاده از مدل‌های زبانی بزرگ (LLM)

- ظرفیت اطلاعاتی بسیار بالاتر (میلیاردها پارامتر) در مقابل مدل کوچک فعلی.
- توانایی درک زمینه و تشخیص کلمات هم‌آوا.
- قابل تنظیم دقیق با داده‌های خاص فارسی.
- **چالش:** تمایل به تصحیح بیش از حد و بازنویسی.

## ۲. افزودن ویژگی‌های واجی (Phonetic Features)

- ترکیب تعبیه‌ی کاراکتری با تعبیه‌ی واجی.
- هر کاراکتر به واج متناظرش نگاشت می‌شود.
- مدل می‌تواند از اطلاعات صوتی برای تمایز نویسه‌های هم‌آوا (ذ/ز/ض/ظ، س/ص/ث) استفاده کند.

## ۳. استفاده از معماری Transformer

- جایگزینی BiLSTM با Transformer.
- مکانیزم Self-Attention برای درک بهتر زمینه.
- Multi-Head Attention برای توجه همزمان به اطلاعات محلی و جهانی.
- امکان کشف روابط پیچیده‌تر بین دو نما.

## ۴. تحقیق در مورد روش‌هایی برای جلوگیری از Shortcut Learning در همین مدل و آزمایش این روش‌ها



**THANK  
YOU**